

15.05.26 ПОИСК ПОДСТРОКИ В СТРОКЕ

h - haystack (text) t

n - needle (pattern) p

"НАИВНЫЙ" АЛГОРИТМ

$n = \text{len}(t)$

$m = \text{len}(p)$

```
def find_substring(t, p):
```

```
    for st_pos in range(len(t) - len(p) + 1):
```

```
        for i in range(len(p)):
```

```
            if (t[st_pos + i] != p[i]):
```

ПЕРЕХ. НА СЛ. ОБОР. ВН. ЦИКЛА

```
    return st_pos
```


```
    return -1
```

сложность: $O(nm)$

МОЖНО БЫСТРЕЕ!

АЛГ. РАБИНА-КАРПА: ВМЕСТО ВН. ЦИКЛА СЧИТАТЬ

ХЭШ ОТ ПОДСТР., С КОТ. СРАВН. ПАТТЕРН



value

hash function

$O(m)$

$O(n+m)??$

НЕТ, ПОСК. ИЗ = ХЭШЕЙ НЕ СЛ.
РАВЕНСТВО СТРОК

ПРИМЕР Ф-ИИ, КОТ. МОЖНО ПОСЧИТ. ЗА $O(1)$, ЗНАА ЗН.

НА ПРЕД. ПОДСТР.:



$$h(s) = \sum_{i=0}^{\text{len}(s)-1} s[i] x^{\text{len}(s)-i} \mod q; \quad x \in [0, q-1]$$

0 и 1 - возможные случаи
q - прост. число

t - строка

$h(t[p+1 : p+1+m])$ - хотим найти за $O(1)$

известно зн. $h(t[p : p+m])$


$$h_1 = h(t[p : p+m]) = \sum_{i=0}^m t[p+i] x^{m-i} \mod q \quad \text{ЗНАЕМ}$$

$$h_2 = h(t[p+1 : p+m+1]) = \sum_{i=0}^m t[p+i+1] x^{m-i} \mod q$$

$$= \sum_{i=1}^{m+1} t[p+i] x^{m-i+1} \mod q \quad \text{ХОТИМ НАЙТИ}$$

КАК ВЫРАЗ. h_2 ЧЕРЕЗ h_1 ?

$$h_2 = (h_1 - t[p] \cdot x^m) x + t[p+m+1] \cdot x^0$$




p, p+1, p+2, p+3 = p+m

худш. случай $O(nm)$

"средний" $O(n + m + \lceil \frac{n}{q} \rceil)$

Алгоритм Бойера-Мура



ПРЕПАРИРОВАТЬ


ПОДСТР. "РО"

ШЛАКОРАСТВОРОБЕТОНМЕЩАЛЬЩИЦА

ПОДСТР. "ОРО"

КОДИРОВАНИЕ ХАФФМАНА



~~ЩАКО РАСТВОРО ВЕТО ИМЕШАЛЪЩИ СЯ~~




BEAM SEARCH

1, 8, 48, ..., 110

log
разм.
слоя



BFS ПРОХ. ВСЕ ГРАФ



BEAM SEARCH ПОДДЕРЖ. ТОП-К КАНДИДАТОВ

НА КАЖД. ШАГЕ:

- 1) КО ВСЕМ КАНД. ПРЕД. ШАГА ПРИМ. ВСЕ ХОДЫ
- 2) ДЕДУПЛИКАЦИЯ
- 3) "ОЦЕНИВАЕМ" КАЖД. СОСТ.
- 4) ОСТАВЛ. ТОП-К

ОЦЕНКА ДЕЛ. С ПОМ. Ф-ИИ, КОТ. ПРИН. СОСТ. И
ВОЗВР. ОЦЕНКУ КР. РАССТ. ДО СОБР.

РАССТОЯНИЕ РЕДАКТИРОВАНИЯ

3 ДЕЙСТВИЯ:

1) УБР. СИМВОЛ

2) ДОБАВ. СИМВОЛ

3) ЗАМЕН. СИМВОЛ

БУИ

БУР


ЗАМЕНА

$$L("БУИ", "БУР") = 1$$

РАССТ. ЛЕВЕНШТЕЙНА - это мин число опер., перев. одну стр. в другую

НАЙТИ МОЖНО ДИНАПРОГОЙ:

		С	Л	О	М
	0	1	2	3	4
Л	1				
О	2				
Т	3				



ВХОД: ТЕКСТ (ИЗ ПРЕДЛОЖЕНИЙ)

ВЫХОД: ДЛЯ КАЖД. СЛОВА ДРУГОЕ, БЛИЖ. ПО ЛЕВЕНШТЕЙНУ

ИГРА СЛОВ



ИГРА СЛОВ